

Relazione Terza Esercitazione in SAS

Autori: Cerasoli Giovanni Giacomo, Ricchebono Alessandro, Tacchella Matteo

Analisi del dataset:

La relazione è relativa a dati su 1500 nuclei familiari, sottoinsieme di 40000 osservazioni raccolte dalla Philippine Statistics Authority nel 2015. Si vuole studiare il numero di componenti familiari in relazione a variabili di tipo geografico, economico e sociale. Le variabili considerate sono 6:

- id: numero identificativo
- location: zona geografica
- age: età del capo famiglia
- total: numero di componenti del nucleo escluso il capo famiglia
- numLT5: numero di componenti del nucleo di età inferiore ai 5 anni
- roof: tipo di tetto

La variabile location è categorica a 5 livelli rispettivamente riferiti alle seguenti zone geografiche: Central Luzon, Davao Region, Ilocos Region, Metro Manila, Visayas. Anche la variabile roof è categorica a due livelli riferiti a: Predominantly Light/Salvaged Material e Predominantly Strong Material; le altre variabili sono numeriche.

Si sceglie di considerare una nuova variabile categorica denominata “fascia” relativa alla suddivisione di age in fasce d’età. Inoltre, si decide di considerare la variabile numLT5 come categorica, poiché assume solo valori da 0 a 4.

Dalle frequenze di roof, si osserva come ci sia una netta predominanza di tetti di materiale prevalentemente resistente (circa 89%).




Figura 1 - frequenze di roof

Dalle frequenze di location si rileva che il 40% circa dei nuclei proviene da Visayas, mentre gli altri si dividono approssimativamente in modo uguale tra le altre località (tra il 12% e il 20% ciascuna).




Figura 2 - frequenze di location

Dalla figura 3, si nota che prevalentemente non sono presenti bambini sotto ai 5 anni (70% circa), meno dell'8% dei nuclei ha 2 o più bambini e il restante 20% circa ha un solo bambino.




Figura 3 - frequenze di numLT5

Dalla figura 4, si rileva che quasi la totalità dei capi famiglia appartengono alle tre fasce centrali (tra 30 e 74 anni) in modo pressoché equidistribuito (prevalenza della fascia 45-59); i restanti (circa il 10%) si distribuiscono nelle due fasce estreme (<30 o >=75).




Figura 4 - frequenze di fascia

In generale, come si è riscontrato sopra, l’esperimento non è bilanciato per alcuna variabile categorica.

Dalla tabella 1, si rileva che i nuclei familiari assumono valori da 0 a 16; osservando media e deviazione standard si può supporre che la maggior parte dei valori siano più vicini al minimo che al massimo.

Variabile di analisi: total				
N	Media	Dev std	Minimo	Massimo
1500	3.6846667	2.3524996	0	16.0000000

Tabella 1 - analisi total

Dai boxplot di total per roof (figura 5), si osserva come non ci siano differenze tra le scatole per i due differenti tipi di tetto; l’unica variazione si ha per la lunghezza del baffo superiore, in cui si nota una maggiore dispersione per il materiale prevalentemente resistente. Anche dall’osservazione dei diagrammi a barre (figura 6) si riscontra come la distribuzione per i due tipi di tetto sia simile; come considerato in precedenza, si nota come ci sia una netta predominanza di nuclei familiari con livello di roof Predominantly Strong Material. Si constata inoltre come nessuna famiglia con più di 11 componenti nel nucleo abbia un tetto con materiale leggero o di recupero.





Figure 5, 6 - total per roof

Dai boxplot relativi a total per location (figura 7), si osserva come non ci siano sostanziali differenze al variare della zona geografica: in particolar modo tra le coppie Central Luzon, Davao Region e Ilocos Region, Metro Manila si rilevano diversità solo per la lunghezza del baffo superiore; inoltre, tra queste 4 regioni la mediana e la media sono molto simili. Le maggiori differenze rispetto alle altre zone geografiche si hanno per Visayas, dove il valore della mediana è più elevato. Dall'analisi della figura 8, si nota nuovamente come la distribuzione sia piuttosto simile, con picchi per la numerosità dei nuclei per i valori 2, 3, 4. In aggiunta, si evidenzia come i nuclei più numerosi siano nella zona geografica Visayas.





Figure 7, 8 - total per location

Dai boxplot relativi a total per fascia (figura 9), si rileva come ci sia una maggior dispersione per le fasce d'età 45-59 e 60-74, mentre, per la prima fascia (<30), la dispersione è minima: total è compreso infatti tra 0 e 5. Per la fascia d'età >=75 si riscontra come la scatola sia spostata verso valori più bassi rispetto alle altre. Dai diagrammi (figura 10) a barre si evidenzia come i nuclei più numerosi abbiano principalmente il capofamiglia di età tra i 45 ed i 59 anni; in generale le distribuzioni per ogni fascia sono comunque simili, con picchi per i valori 2, 3, 4, 5.





Figure 9, 10 - total per fascia

Dalle figure 11 e 12, si osserva come all'aumentare dei bambini con età inferiore ai 5 anni incrementi anche il numero di componenti del nucleo; tuttavia, si nota come le famiglie con più di un bambino con meno di 5 anni siano considerevolmente meno numerose delle altre.





Figure 11, 12 - total per numLT5

Analisi modelli lineari generalizzati:

Si riportano parti degli output (tabelle 2, 3, 4 e figure 13, 14, 15) relativi a: un modello lineare generalizzato, modellato da una Poisson, un modello con la radice quadrata della variabile total, mantenendo il modello con la Poisson, ed uno modellato da una normale, considerando la radice quadrata di total. Si vuole studiare la variabile total al variare di location, roof, fascia, numLT5; per location si sceglie Metro Manila come livello di riferimento.

Confrontando i primi due grafici dei residui (figure 13 e 14) si nota come il modello Poisson con la radice quadrata sia migliore, infatti, la nuvola di punti è più omogenea; ciò viene confermato anche dall'indice AIC più basso. Considerando invece il modello normale confrontato con il modello Poisson con radice, si osserva dall'output (tabella 4) che l'indice AIC è considerevolmente più basso e che il valore della devianza è maggiore. Tuttavia, il grafico dei residui (figura 15), nonostante presenti una nuvola di punti abbastanza omogenea, risulta più dispersivo rispetto a quello visto sopra (figura 14).

Criteri di valutazione della bontà di adattamento

Criterio	DF	Valore	Valore/DF
Devianza	1486	1743.7337	1.1734
Dev. scalata	1486	1743.7337	1.1734
Chi-quadrato di Pearson	1486	1623.2046	1.0923
X2 Pearson scal.	1486	1623.2046	1.0923
Log verosimiglianza		1990.5804	
Log verosimiglianza piena		-3058.3066	
AIC (minore è meglio)		6144.6132	
AICC (minore è meglio)		6144.8960	
BIC (minore è meglio)		6218.9982	

Tabella 2 - Poisson




Figura 13 - Poisson

Criteri di valutazione della bontà di adattamento

Criterio	DF	Valore	Valore/DF
Devianza	1486	440.4231	0.2964
Dev. scalata	1486	440.4231	0.2964
Chi-quadrato di Pearson	1486	322.8223	0.2172
X2 Pearson scal.	1486	322.8223	0.2172
Log verosimiglianza		-1071.2630	
Log verosimiglianza piena		-2009.8080	
AIC (minore è meglio)		4047.6160	
AICC (minore è meglio)		4047.8988	
BIC (minore è meglio)		4122.0011	

Tabella 3 - Poisson con radice




Figura 14 - Poisson con radice

Criteri di valutazione della bontà di adattamento

Criterio	DF	Valore	Valore/DF
Devianza	1486	532.6911	0.3585
Dev. scalata	1486	1500.0000	1.0094
Chi-quadrato di Pearson	1486	532.6911	0.3585
X2 Pearson scal.	1486	1500.0000	1.0094
Log verosimiglianza		-1351.9488	
Log verosimiglianza piena		-1351.9488	
AIC (minore è meglio)		2733.8977	
AICC (minore è meglio)		2734.2211	
BIC (minore è meglio)		2813.5960	

Tabella 4 - Normale con radice




Figura 15 - Normale con radice

In generale, considerando i p-value delle variabili esplicative (output non riportato), si rileva che quelli che vanno ad incidere maggiormente sul valore di total siano fascia d'età ed il numero di bambini d'età inferiore a 5 anni.

In conclusione, dalle analisi effettuate si è rilevato come il totale non sia influenzato dalle altre variabili in modo significativo. Tuttavia, si evidenzia che le variabili relative all'età del capo famiglia (fascia) ed alla condizione economica (roof) vadano ad incidere maggiormente rispetto alle altre.